DSAI4901 · CAPSTONE 進度簡報

由生成，到可驗證

以可量度的版面可用性，作為論文轉簡報的控制訊號

CHAN Yee Tung

指導老師： Dr. Jibin Wu · 2026 年 10 月 29 日

文獻現況

兩大家族，缺一件工具

工作	提供什麼	仍留下什麼
PPTAgent 、 SlideGen 、 SlideLab 、 ArcDeck	強生成器；敘事規劃	這份 deck 到底能不能用；局部、機械性的失敗
ReDeck 、 PPTPilot 、 SLIDEFORGE	會讀渲染回饋的修復迴圈	哪一類缺陷對修復有反應，反應幾大
SlideAudit 、 DECKBench 、 PresentBench	缺陷分類法；對照參考 deck 評分	生成之後才到；需要目標 deck 或標註

合起來看，這個領域很會做 deck，也很會在事後打分，但中間那一段沒有接上。

工具來得太遲，指揮不到生成；真的用得著的時候，又不可分解。

> 缺口：冇一件工具跑在迴圈裡面，冇一件把分數拆得開。一個 deck 層面的數字，講不出應該修哪一類缺陷。

為什麼做這個方向

文獻沒有做的三件事

歸因缺失

ReDeck 與 PPTPilot 都會修，但 deck 升十分，講不出是哪一類缺陷對修復有反應。

量度是事後的

SlideAudit 與 DECKBench 評的是成品。生成之後才到的分數，指揮不到生成。

工具需要參考或標註

要一個目標 deck，或者人手標註圖像。兩者在生成時都對任意 .pptx 算不到。

所以貢獻不是又一個生成器，也不是一套新分類法。

- **而是一層量度**：無需參考、在物件模型上計算、便宜到可以跑在迴圈裡面。
- **以及研究這個量度值多少** —— 按違規類別計，對照成本。

問題

一個缺口，兩條研究問題

> *「簡報品質現在可以事後量度。這些工具答不到的是：量度本身能不能驅動生成。」*

RQ1 一組機械性的 gate，能不能取代參考 deck 或人手標註，而仍然按人會給的次序排列 deck？

RQ2 把這個訊號放進迴圈裡，實際加了多少？按違規類別計，成本又是幾多？

兩條問題由同一件東西回答：一份 deck、一個分數、一份修復記錄。

系統

七個零件，其中四個用到模型

A　生成 —— 文字層，寫定即凍結

parse	claims AI	requirement AI	select	outline AI	bullets+notes AI	render
PDF → 章節、圖、圖說	斷言，附上 evidence id	幾分鐘、聽眾是誰 → 一張表	逐條 claim 決定要或不要	重排成一條 論證	壓縮，再寫成 講稿	原生、可再編輯的 .pptx

B　量度 —— 六個 gate，直接在 .pptx 物件模型上，不渲染

G1 出界	G2 重疊	G3 字級	G4 對比	G5 文字溢出	G6 密度	SRR	ready?

1　量度
先找最嚴重那一項

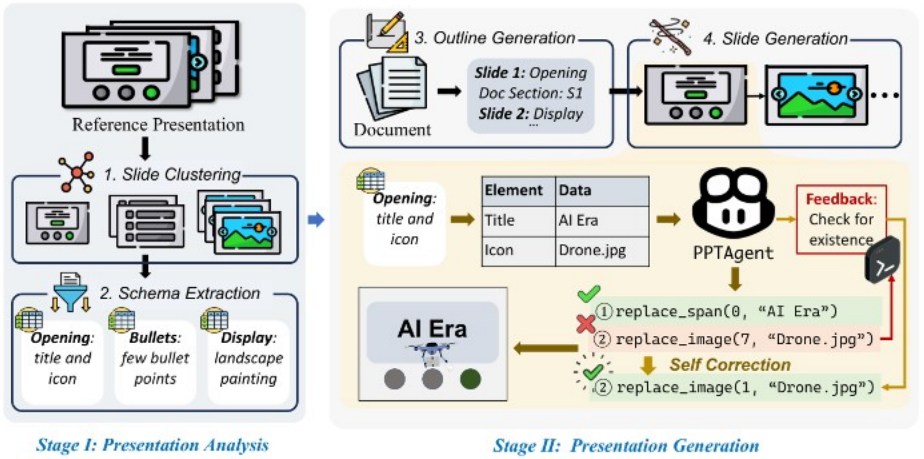
2　修復
最便宜、可還原的動作

3　再量
每秒、每元的改善

只有文字層可以改字。修復可以移、可以縮、可以換色，但永遠不可以加內容或改數字。這樣「迴圈令 deck 變好」才不會同「迴圈改寫了 deck」混在一起。

圖說是裁出來的，不是抽出來的

- **章節標題**靠字級與粗體判斷，不靠固定清單。
- **圖**在這個領域多數是向量圖：抽內嵌圖片只會抽到 32×32 的 icon 。所以按圖說的位置裁出區域，再以 200 dpi 光柵化。
- **裁切的界線停在最近的段落**，不是停在任何文字方塊 —— 圖裡面本身有標籤，停在標籤就會把圖切一半。



PPTAgent 的 Figure 2，直接由 PDF 裁出來

這篇論文 32 個圖說之中， 12 個裁出可用的圖。失敗的是「圖說在表格上方」與「跨兩欄的圖」。兩者都可以修；而產生這 12 張的規則，就是評估時會用的同一條。

選段是一張表，不是一個判斷

要求	一定保留	有空間才保留	丟掉
5 分鐘、一般聽眾	results 、 conclusion	method (core only)	analysis, limitations
12 分鐘、專家	results 、 conclusion 、 method 、 motivation 、 background 、 analysis	related work 、 setup	—

每一條被保留或被丟掉的 claim ，都帶著決定它的規則編號：

claim	章節	重要度	決定	規則編號	原因
c3	results	3	保留	hard:results	results 永遠保留
c7	setup	2	丟掉	table:12:setup	12 分鐘的 talk 不講
c9	analysis	1	丟掉	importance:cut2	重要度 1 低於門檻 2

模型只出現在兩個邊界：把自由文字的要求轉成那張表，以及抽取 claim 。中間的取捨是查表，所以第二個人可以重跑一次。

零件三 · 量度

六個 gate 做了四個，兩個是下一步

gate	規則	門檻	狀態
G1 出界	所有形狀在版面內	0 pt	已做
G2 重疊	文字交集 ÷ 較小框	> 5 %	已做
G3 字級	內文與標題，按角色	角色下限	已做 · 全局
G6 密度	字數與 bullet，按角色	角色上限	已做 · 全局
G4 對比	WCAG 2.2 AA，字對背景	4.5 : 1	下一步
G5 文字溢出	渲染高度 ÷ 框高	≤ 0.95	下一步

SRR

可判斷的檢查之中，通過的比例。權重全部相等，沒有 fit 出來的數；判斷不到的檢查不計入平均，但會令 deck-ready 不成立。

為什麼不用權重

任何權重都是一個沒有證據的數 —— 同報告反對「24 點字」的理由一樣。

G4 與 G5 是兩個真正需要解析度的：顏色要穿過主題與 z-order 解析，文字高度要用字體度量估算。兩者都排在迴圈之前，因為一個不能信的指標，不能當訊號。

範圍

可以量的有 65 項，值得做的有 6 項

候選	數量
A 版面幾何	14
B 字體與排版	15
C 顏色與對比	7
D 內容與語意	12
E 結構	8
F 渲染	5
G 觀眾	4
合計	65

五個條件

- 可判定：不需要參考答案
- 確定性：同一份檔案同一個分數
- 違規就是變壞，不是不同
- 便宜到可以跑在迴圈裡
- 可解釋：指得出形狀、數值、門檻

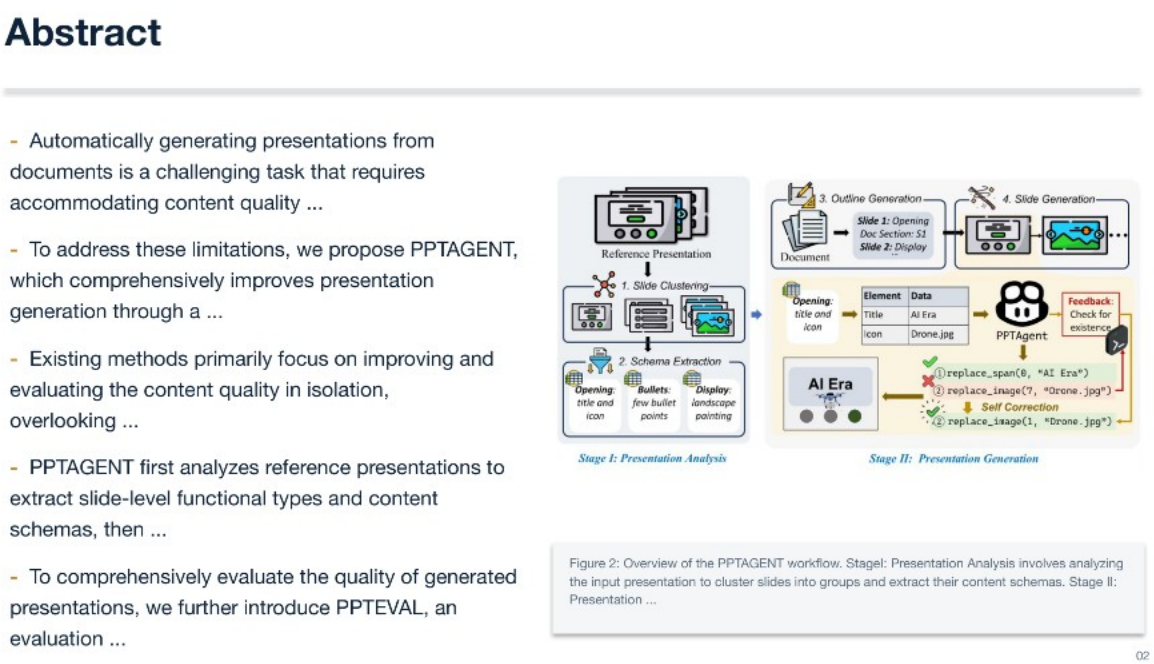
最後留下的

gate	來源
G1 出界	A1
G2 重疊	A2
G3 字級	B1
G4 對比	C1
G5 文字溢出	B7
G6 密度	B5+B6

> 而它看不見什麼：一句 bullet 可以語法正確、長度正常、字級正確 —— 而完全冇意義。這就是機械式量度的邊界，屬於人評。

目前結果

每一張生成出來的 slide 都至少違反一個 gate



Abstract

- Automatically generating presentations from documents is a challenging task that requires accommodating content quality ...
- To address these limitations, we propose PPTAGENT, which comprehensively improves presentation generation through a ...
- Existing methods primarily focus on improving and evaluating the content quality in isolation, overlooking ...
- PPTAGENT first analyzes reference presentations to extract slide-level functional types and content schemas, then ...
- To comprehensively evaluate the quality of generated presentations, we further introduce PPTEVAL, an evaluation ...

Figure 2: Overview of the PPTAGENT workflow. Stage I: Presentation Analysis involves analyzing the input presentation to cluster slides into groups and extract their content schemas. Stage II: Presentation ...

02

生成的 deck 第 2 頁：圖已放入，圖說在下面

	PPTAgent	DOC2PPT
頁數	9	9
合格頁	0	0
SRR （頁面級）	0.00	0.00
違規數	33	32
G3 違規頁	9 / 9	9 / 9
G6 違規頁	8 / 9	8 / 9

這是預期結果，不是缺陷： baseline 生成器完全不理會這些 gate 。重點是這個數字可以重跑，而違規是逐項命名的。

實際執行

整條 pipeline 跑得完，而且會老實地報錯

```
capstone-ppt-agent — zsh
%  ./run.sh research/pdfs/DOC2PPT_2101.11796.pdf
[1/3] parse
sections=8 captions=24 figures=11 (clipped=11) -> build/DOC2PPT_2101.11796.deck.json
  p1   Abstract                                              952 chars
  p2   Approach                                            15126 chars
   ...
  p7   Conclusion                                          10298 chars
[2/3] compose
slides=8 -> build/DOC2PPT_2101.11796.plan.json
    Abstract                                    bullets=6 90s
[3/3] render
slides=9 -> out/DOC2PPT_2101.11796.pptx
done -> out/DOC2PPT_2101.11796.pptx

%  python3 src/detect.py out/DOC2PPT_2101.11796.pptx
out/DOC2PPT_2101.11796.pptx
  slides=9  clean=0  SRR=0.0
  violations=32  by gate={'G3': 9, 'G6': 8}
    p1<G3> TextBox 4 at 14 pt
    p2<G3> TextBox 6 at 9.5 pt
    p2<G6> 783 chars
    ...

%  python3 -m pytest
....................................................................  [100%]
76 passed in 3.4s
```

真實終端輸出；中間幾行省略。

parse
8 個章節、 24 個圖說、裁出 11 張圖

compose
8 張 slide，每張 90 秒

render
9 頁 deck，原生可編輯

detect
32 個違規， SRR 0.00

pytest
76 個測試全綠

狀態

做好了什麼，下一步是什麼

已做好並有測試

- parse： 章節、圖、圖說
- 裁圖：樣本上 32 個圖說成功 12 個
- render： 原生 .pptx 連講稿
- G1 、 G2 、 G3 、 G6 + SRR
- 選段規則表， 55 個測試函數

部分完成

- G3 / G6 仍然用一個全局門檻
- 圖說截斷要改成詞語邊界
- claim 仍然由 heuristic 抽取

未開始

- G4 對比、 G5 文字溢出
- 修復動作與迴圈
- 110 張測試集與標註
- 人手 deck 、 baseline 、 2×2 實驗

76 個測試全綠。上面那份 deck 就是這條 pipeline 由頭到尾跑出來的。

計劃

實驗設計，與時間表

設計： 2 × 2 因子

	不檢查	開檢查
基礎模型	A1	A2
fine-tuned	A1'	A2'

A2 − A1 隔離出檢查帶來的增益。 fine-tune 那一行測試這個增益在更強生成器下是否仍然存在。

fine-tune 那一臂是條件性的：只有主結果出來、而且剩下四週 buffer 才會跑。

週次	工作	里程碑
W1–2	範圍與文獻	提案 11/5
W3–7	rulebook 、六個 gate 、校準	效度檢查
W8–11	修復動作、 110 張測試集	中期報告 1/7
W12–18	迴圈、消融、 20 人研究	偏好相關性
W19–23	報告、 demo 、簡報	最終 4/8

兩個效度檢查在主要研究之前跑： deck 要排成 人手 > PPTAgent > naive ； SRR 要跟隨人類偏好。相關係數會預先註冊，無論結果如何都報。

需要你的意見

三個決定，一個問題

1

人手 deck

哪裡可以拿到作者真正上台用的 deck？它是效度檢查的上界，而我手上完全沒有。

2

範圍

單欄英文論文、10–12 張、8 篇 held-out —— 這樣窄到做得完，還是窄到不能推廣?

3

Gate 集

六個機械性 gate，密度與字級用掃描而不是擬合。這樣站得住腳，還是應該減一個?

另外想聽你的看法：一個確定性的 detector，在這裡會被視為優點，還是被視為 AI 成分不足?