從生成，到可驗證

以可量度的版面可用性，作為論文轉簡報的控制訊號

CHAN Yee Tung · DSAI4901 Capstone · 指導老師：Dr. Jibin Wu · 2026 年 10 月

---

1. 背景

一場會議演講只有十至十五分鐘，要講完一篇佔八頁的論文。所以 deck 不是論文的摘要，而是把論文壓縮成一條觀眾能即時跟上的論證。這個壓縮過程很慢：作者要決定留什麼、為每個論點找回那張圖，再把兩者放進一頁仍然能在房間後排看得清的版面。

語言模型現在一分鐘內就能從一篇論文產生一份看起來合理的 deck。本項目的起點不是它們能不能做，而是結果能不能用——以及系統自己知不知。

第二個問題之所以重要，是因為失敗並不細微。文字框跑出邊界、兩個元素重疊、caption 壓在深色背景上、一頁塞了二百五十字：這些都是機械性失敗，投影的一刻就看得見。而這些正是語言模型看不見的失敗，因為它從不渲染自己寫的東西。

2. 現時的做法

這個領域的工作大致分成兩類，旁邊長出一套評測文獻。

生成。PPTAgent 把做 deck 視為編輯而非撰寫：分析參考簡報、抽出 slide 層級的 schema、輸出編輯動作。SlideGen、SlideLab、ArcDeck 加上敘事規劃與多模態接地。這些系統產出的 deck 有說服力，在盲測偏好上可與商業工具競爭。

修復。ReDeck 把修訂拆成原子編輯動作，每步之後取回 renderer 的觀測。PPTPilot（隨 PPTArena 提出）跑 plan–edit–check 迴圈，由視覺語言模型判斷結果。SLIDEFORGE 把 slide 保持為結構化物件，令編輯不破壞原生可編輯性。

評測。SlideAudit（UIST '25）提供 27 類版面缺陷的分類法，涵蓋 2,400 張已標註 slide。DECKBench（KDD '26）以參考 deck 作比對，用相似度指標加 LLM judge 評分。PresentBench 用細緻的 rubric 評生成品質。

表 1. 各部分工作提供了什麼，又留下了什麼。

工作	提供什麼	仍未解決
PPTAgent, SlideGen, SlideLab	強生成器；敘事規劃	輸出是否可用；局部失敗
ReDeck, PPTPilot, SLIDEFORGE	帶渲染回饋的修復迴圈	哪些修復有用、有多少用
SlideAudit	缺陷分類法；2,400 張標註	無迴圈；基於圖像；無逐類修復分析
DECKBench	對照參考 deck 的評分	需要目標 deck；只排名，不驅動

3. 好在哪裡，差在哪裡

三件事真的解決了。Deck 看起來像真：版面穩定、風格一致。輸出的可編輯性提升，因為工作已進入 .pptx 物件層。評測亦由整體打分成熟到任務式量度——只用成品答問題，或用明確準則判斷可用性。

四件事仍未解決。

- 歸因缺失。ReDeck 與 PPTPilot 都跑修復迴圈，但都沒有報「哪一類缺陷對修復有反應、哪一類沒有」。deck 層面升十分，只告訴我們迴圈有用，沒告訴我們用在哪裡。
- 量度是事後的。SlideAudit 與 DECKBench 評的是已完成的作品。生成之後才到的分數，無法指揮生成。
- 工具需要參考或標註。DECKBench 要目標 deck；SlideAudit 要人手標註圖像。兩者都無法在執行時對任意 .pptx 計算。
- 閾值是慣例。用來判斷一頁是否太密的數字——六個 bullet、三十字、24pt——被廣泛重複，卻少有證據，第 6 節會說明。

4. 我們對文獻的判讀

合起來看，這個領域很會做 deck，也很會在事後打分，但沒有把兩者接上。工具來得太遲，真的用得著的時候又不可分解。

這就是本項目處理的缺口。它刻意窄：不是又一個生成器，不是新分類法，而是一層可以在生成期間計算的量度，以及研究這個量度值多少。

5. 為何值得做

第一，這些失敗是機械性的，可以用確定性方法判定。形狀有沒有超出 slide、兩個文字框有沒有相交、一對顏色有沒有達到對比要求：這些是算術，不是判斷。規則可以審核；模型的意見不可以。

第二，可用性是前提。一頁讀不到的 deck，無論內容選得多好都是失敗。在讀不到的頁上改進內容，不會令演講更好。

第三，結果可以轉移。如果量度無需參考、又在物件模型上計算，就可以套用到任何系統產生的任何 deck——包括本項目用來比較的 baseline。這令比較公平，也令成果可重用。

6. 慣例，不是證據

業界不缺規則。例如 IEEE NMDC 的作者指引寫明「不要使用小於 24 point 的字級」，文字頁「不多於 30 字、不多於 6 行」。建議清楚、廣為跟隨，而且完全沒有引用證據。文中沒有任何研究支持；其他會議給的數字又不一樣。

而這些規則之間彼此矛盾。六六法則允許每行六字、共六行，即一頁三十六字；上述指引卻把同一頁上限訂在三十字。兩者都寫得斬釘截鐵，兩者都沒有引用研究，而實務界已有文章主張六六法則應該淘汰。當兩條被廣泛使用的慣例相差百分之二十，而兩者都指不出證據，被傳遞下去的其實是習慣，不是知識。

這裡值得分開三種錨定，因為它們份量不同，設計上必須區別對待。

表 2. 三種錨定。只有第一種是通常意義下的證據；第三種只有在樣本支持時才算證據。

錨定類型	例子	從哪裡來	能否支撐量度
正式標準	WCAG 2.2 AA 對比 4.5:1	知覺研究，經規範固定	可以——可對使用者驗證
實務慣例	24 pt；30 字；6 行	在指南間重複，無引用鏈	不可以——是預設值，不是發現
經驗數值	重疊大於 5%	對特定語料擬合	只有在樣本足夠時才可以

慣例之所以流傳，原因與效度無關。它們容易寫、容易查，而且表面上合理。當一條慣例是錯的，沒有人需要負責，因為錯的閾值帶來的代價看不見：一頁稍為太密，簡報照樣進行，觀眾只是讀得少一點。一條指引可以單靠「聽起來合理」流傳幾十年。

真要驗證一條慣例，需要做什麼？改變數值、固定內容與觀眾，然後量度理解或偏好——這個設計有嚴重的混淆，因為內容質素的影響遠大於密度。這種研究在簡報領域並不存在，也不是本項目的貢獻。所以誠實的立場不是「慣例錯了」，而是「慣例承擔不起一件量度工具的重量」。

後果是方法論上的。沒有已驗證的值可以 fit，而四十張校準 slide 支撐不起六個 fit 出來的閾值——每個 gate 大約六張——這樣選出的值只會是樣本的產物。所以設計改為按來源分開 gate：

表 3. Gate 來源。兩個 gate 由規則或公開標準固定；其餘四個只掃描，全部不 fit。

Gate	規則	閾值	來源
G1 出界	所有形狀在版面內	0 pt	二元規則——無自由參數
G4 對比	WCAG 2.2 AA，填充對背景	4.5:1（大字 3:1）	公開標準
G3 字級	依 slide 角色的內文字與標題	按角色	慣例；掃描，不 fit
G6 密度	依角色的字數與 bullet 數	按角色	慣例；掃描，不 fit
G2 重疊	文字交集 ÷ 較小框	> 5%	經驗值；掃描
G5 文字溢出	渲染高度 ÷ 框高	≤ 0.95	渲染容差；掃描

「掃描，不 fit」的意思是：數值在一段範圍內報告，結論只有在整段範圍都成立時才接受。兩個標準錨定的 gate 完全沒有自由參數。由於本項目自己生成 deck，每頁的角色——標題、議程、內容、圖表、結論——在生成時已知，所以密度與字級可以按角色不同，而不需要分類器。這就消除了「標題頁與方法頁不能共用同一密度上限」的反對：它們不再共用。

7. 計劃與時間表

工作分四條流。每條都獨立可報告，所以一條滑掉，不會令整個項目沒有結果。

- W1 量度。在 .pptx 物件模型上實作六個 gate；對每份 deck 計算 SRR 與 deck-ready。
- W2 修復。每類違規一個決策程序，先做最便宜且可逆的動作，並有護欄禁止新增內容或改動數字。

- W3 控制。在 W1 的訊號下套用 W2 的迴圈：貪心、迭代，再到預算感知。
- W4 證據。以人手標註驗證 detector；跨系統的區辨效度；驗證器的受控消融；人評。

兩個檢查在主要研究之前執行，因為任何一個失敗都會令其餘失效。區辨效度問：SRR 有否按應有的次序排列系統——人手做的 deck 高於 PPTAgent，高於 naive pipeline。如果人手 deck 不是最高分，就是 gate 定義有誤，必須在任何迴圈開跑之前修訂。收斂效度問：SRR 是否跟隨人類偏好。該相關性會預先註冊，無論結果如何都會報告。

有兩處刻意偏離 brief 建議的時間表。第一，brief 把「檢查」放在第 5 階段（第 12–14 週）；本項目提前到第 5 週，因為指標必須先驗證，依賴它的迴圈才建得穩。第二，brief 第 6 階段列明比較六個維度：accuracy、coverage、readability、design、latency、cost。其中 coverage——論文的重點有幾多留在 deck 裡——會獨立量度，每篇標註五至八個 claim，令六個維度全部有數。

表 4. 對照大學時間表的排程。

週	工作流	交付	里程碑
W1–2	範圍與文獻	38 篇已讀；缺口確定	Proposal：11 月 5 日
W3–4	環境與 spike	解析與渲染可用	Workshop 1：11 月 9 日
W5–7	Rulebook 與 detector	六個 gate；40 張校準	區辨效度檢查
W8–11	版面與渲染	修復動作；110 張測試集	首次 SRR 比較
W12–14	校準與迴圈	掃描凍結；迴圈收斂	Interim：2027 年 1 月 7 日
W15–18	實驗與人評	消融；20 人研究	偏好相關性
W19–20	報告與示範	報告、demo、slides	Final：4 月 8 日；簡報 4 月 9–21 日

8. 聲明

本文件在撰寫與程式碼生成上使用了生成式 AI 工具。所有設計決定、指標定義、評測協議、標註與分析，均為作者本人所做。所用工具及其使用程度記錄於日誌，連同報告一併提交，符合大學的生成式 AI 使用指引。

References

Chen, H., Zhou, X., Zhou, W., et al. (2026). X+Slides: Benchmarking audience-conditioned slide generation. arXiv:2606.19256.

Hu, H., Dang, C., Liu, Y., et al. (2026). PosterMELD: Multi-agent paper-to-poster generation with editable print-ready outputs. arXiv:2608.02218.

Huang, Z., Liu, X., Hu, T., Zhang, K., & Liu, Y. (2025). PPTBench: Holistic evaluation of LLMs for PowerPoint layout and design understanding. arXiv:2512.02624.

IEEE Nanotechnology Materials and Devices Conference. (2021). Presentation preparation guidelines and requirements. https://ieeenmdc.org/past-conferences/nmdc-2021/call-for-papers/presentation-preparation-guidelines-and-requirements/

Jang, D., Heisler, M. L., Xing, L., et al. (2026). DECKBench: Benchmarking multi-agent frameworks for academic slide generation and editing. arXiv:2602.13318.

Ofengenden, M., Man, Y., Pang, Z., Gui, L.-Y., & Wang, Y.-X. (2025). PPTArena: A benchmark for PowerPoint editing. arXiv:2512.03042.

Ozden, T. C., VS, S., Horoz, F., et al. (2026). Narrative-driven paper-to-slide generation via ArcDeck. arXiv:2604.11969.

Pang, W., Lin, K. Q., Jian, X., He, X., & Torr, P. (2025). Paper2Poster: Towards multimodal poster automation from scientific papers. arXiv:2505.21497.

Tian, M., Zeng, Z., Yang, Y., et al. (2026). ReDeck: Step-level render-grounded refinement for document-to-slide generation. arXiv:2609.00194.

Vats, V., Sharma, K., & Wang, Y. (2026). SlideLab: Audience-centered scientific slide generation and evaluation. arXiv:2609.30294.

Zhang, Z. J., Chen, R., Zhong, M., & Wobbrock, J. O. (2025). SlideAudit: A dataset and taxonomy for automated evaluation of presentation slides. arXiv:2508.03630.

Zheng, H., Guan, X., Kong, H., et al. (2025). PPTAgent: Generating and evaluating presentations beyond text-to-slides. arXiv:2501.03936.

Zheng, H., Mo, G., Yan, X., et al. (2026a). DeepPresenter: Environment-grounded reflection for agentic presentation generation. arXiv:2602.22839.

Zheng, H., Wang, F., Xiong, T., et al. (2026b). SLIDEFORGE: An LLM agent for controllable editing of slides as structured artifacts. arXiv:2609.03109.