從生成，到可驗證

以可量度的版面可用性，作為論文轉簡報的控制訊號

CHAN Yee Tung · DSAI4901 Capstone · 指導老師：Dr. Jibin Wu · 2026 年 10 月

---

1. 背景

一場會議演講只有十至十五分鐘，要講完一篇佔八頁的論文。所以 deck 不是論文的摘要，而是把論文壓縮成一條觀眾能即時跟上的論證。這個壓縮過程很慢：作者要決定留什麼、為每個論點找回那張圖，再把兩者放進一頁仍然能在房間後排看得清的版面。

語言模型現在一分鐘內就能從一篇論文產生一份看起來合理的 deck。本項目的起點不是它們能不能做，而是結果能不能用——以及系統自己知不知。

第二個問題之所以重要，是因為失敗並不細微。文字框跑出邊界、兩個元素重疊、caption 壓在深色背景上、一頁塞了二百五十字：這些都是機械性失敗，投影的一刻就看得見。而這些正是語言模型看不見的失敗，因為它從不渲染自己寫的東西。

2. 現時的做法

這個領域的工作大致分成兩類，旁邊長出一套評測文獻。

生成。PPTAgent 把做 deck 視為編輯而非撰寫：分析參考簡報、抽出 slide 層級的 schema、輸出編輯動作。SlideGen、SlideLab、ArcDeck 加上敘事規劃與多模態接地。這些系統產出的 deck 有說服力，在盲測偏好上可與商業工具競爭。X+Slides 更把聽眾當作明確的條件輸入，而不是常數（Chen et al., 2026）。

修復。ReDeck 把修訂拆成原子編輯動作，每步之後取回 renderer 的觀測。PPTPilot（隨 PPTArena 提出）跑 plan–edit–check 迴圈，由視覺語言模型判斷結果。SLIDEFORGE 把 slide 保持為結構化物件，令編輯不破壞原生可編輯性。DeepPresenter 再以環境接地的反思延伸這條迴圈（Zheng et al., 2026a）。

評測。SlideAudit（UIST '25）提供 27 類版面缺陷的分類法，涵蓋 2,400 張已標註 slide。DECKBench（KDD '26）以參考 deck 作比對，用相似度指標加 LLM judge 評分。PresentBench 用細緻的 rubric 評生成品質。PPTBench 問的是另一個問題——模型到底懂不懂版面與設計（Huang et al., 2025）。

表 1. 各部分工作提供了什麼，又留下了什麼。

工作	提供什麼	仍未解決
PPTAgent, SlideGen, SlideLab	強生成器；敘事規劃	輸出是否可用；局部失敗
ReDeck, PPTPilot, SLIDEFORGE	帶渲染回饋的修復迴圈	哪些修復有用、有多少用
SlideAudit	缺陷分類法；2,400 張標註	無迴圈；基於圖像；無逐類修復分析
DECKBench	對照參考 deck 的評分	需要目標 deck；只排名，不驅動

3. 好在哪裡，差在哪裡

三件事真的解決了。Deck 看起來像真：版面穩定、風格一致。輸出的可編輯性提升，因為工作已進入 .pptx 物件層；PosterMELD 在壁報上展示同一個轉向，輸出可印刷、可編輯的成品（Hu et al., 2026）。評測亦由整體打分成熟到任務式量度——只用成品答問題，或用明確準則判斷可用性。

四件事仍未解決。

- 歸因缺失。ReDeck 與 PPTPilot 都跑修復迴圈，但都沒有報「哪一類缺陷對修復有反應、哪一類沒有」。deck 層面升十分，只告訴我們迴圈有用，沒告訴我們用在哪裡。
- 量度是事後的。SlideAudit 與 DECKBench 評的是已完成的作品。生成之後才到的分數，無法指揮生成。
- 工具需要參考或標註。DECKBench 要目標 deck；SlideAudit 要人手標註圖像。兩者都無法在執行時對任意 .pptx 計算。
- 閾值是慣例。用來判斷一頁是否太密的數字——六個 bullet、三十字、24pt——被廣泛重複，卻少有證據，第 6 節會說明。

4. 我們對文獻的判讀

合起來看，這個領域很會做 deck，也很會在事後打分，但沒有把兩者接上。工具來得太遲，真的用得著的時候又不可分解。

這就是本項目處理的缺口。它刻意窄：不是又一個生成器，不是新分類法，而是一層可以在生成期間計算的量度，以及研究這個量度值多少。

5. 為何值得做

第一，這些失敗是機械性的，可以用確定性方法判定。形狀有沒有超出 slide、兩個文字框有沒有相交、一對顏色有沒有達到對比要求：這些是算術，不是判斷。規則可以審核；模型的意見不可以。

第二，可用性是前提。一頁讀不到的 deck，無論內容選得多好都是失敗。在讀不到的頁上改進內容，不會令演講更好。

第三，結果可以轉移。如果量度無需參考、又在物件模型上計算，就可以套用到任何系統產生的任何 deck——包括本項目用來比較的 baseline。這令比較公平，也令成果可重用。

6. 慣例，不是證據

業界不缺規則。例如 IEEE NMDC 的作者指引寫明「不要使用小於 24 point 的字級」，文字頁「不多於 30 字、不多於 6 行」。建議清楚、廣為跟隨，而且完全沒有引用證據。文中沒有任何研究支持；其他會議給的數字又不一樣。

而這些規則之間彼此矛盾。六六法則允許每行六字、共六行，即一頁三十六字；上述指引卻把同一頁上限訂在三十字。兩者都寫得斬釘截鐵，兩者都沒有引用研究，而實務界已有文章主張六六法則應該淘汰。當兩條被廣泛使用的慣例相差百分之二十，而兩者都指不出證據，被傳遞下去的其實是習慣，不是知識。

這裡值得分開三種錨定，因為它們份量不同，設計上必須區別對待。

表 2. 三種錨定。只有第一種是通常意義下的證據；第三種只有在樣本支持時才算證據。

錨定類型	例子	從哪裡來	能否支撐量度
正式標準	WCAG 2.2 AA 對比 4.5:1	知覺研究，經規範固定	可以——可對使用者驗證
實務慣例	24 pt；30 字；6 行	在指南間重複，無引用鏈	不可以——是預設值，不是發現
經驗數值	重疊大於 5%	對特定語料擬合	只有在樣本足夠時才可以

慣例之所以流傳，原因與效度無關。它們容易寫、容易查，而且表面上合理。當一條慣例是錯的，沒有人需要負責，因為錯的閾值帶來的代價看不見：一頁稍為太密，簡報照樣進行，觀眾只是讀得少一點。一條指引可以單靠「聽起來合理」流傳幾十年。

真要驗證一條慣例，需要做什麼？改變數值、固定內容與觀眾，然後量度理解或偏好——這個設計有嚴重的混淆，因為內容質素的影響遠大於密度。這種研究在簡報領域並不存在，也不是本項目的貢獻。所以誠實的立場不是「慣例錯了」，而是「慣例承擔不起一件量度工具的重量」。

後果是方法論上的。沒有已驗證的值可以 fit，而四十張校準 slide 支撐不起六個 fit 出來的閾值——每個 gate 大約六張——這樣選出的值只會是樣本的產物。所以設計改為按來源分開 gate：

表 3. Gate 來源。兩個 gate 由規則或公開標準固定；其餘四個只掃描，全部不 fit。

Gate	規則	閾值	來源
G1 出界	所有形狀在版面內	0 pt	二元規則——無自由參數
G4 對比	WCAG 2.2 AA，填充對背景	4.5:1（大字 3:1）	公開標準
G3 字級	依 slide 角色的內文字與標題	按角色	慣例；掃描，不 fit
G6 密度	依角色的字數與 bullet 數	按角色	慣例；掃描，不 fit
G2 重疊	文字交集 ÷ 較小框	> 5%	經驗值；掃描
G5 文字溢出	渲染高度 ÷ 框高	≤ 0.95	渲染容差；掃描

「掃描，不 fit」的意思是：數值在一段範圍內報告，結論只有在整段範圍都成立時才接受。兩個標準錨定的 gate 完全沒有自由參數。由於本項目自己生成 deck，每頁的角色——標題、議程、內容、圖表、結論——在生成時已知，所以密度與字級可以按角色不同，而不需要分類器。這就消除了「標題頁與方法頁不能共用同一密度上限」的反對：它們不再共用。

7. 計劃與時間表

工作分四條流。每條都獨立可報告，所以一條滑掉，不會令整個項目沒有結果。

- W1 量度。在 .pptx 物件模型上實作六個 gate；對每份 deck 計算 SRR 與 deck-ready。
- W2 修復。每類違規一個決策程序，先做最便宜且可逆的動作，並有護欄禁止新增內容或改動數字。
- W3 控制。在 W1 的訊號下套用 W2 的迴圈：貪心、迭代，再到預算感知。
- W4 證據。以人手標註驗證 detector；跨系統的區辨效度；驗證器的受控消融；人評。

兩個檢查在主要研究之前執行，因為任何一個失敗都會令其餘失效。區辨效度問：SRR 有否按應有的次序排列系統——人手做的 deck 高於 PPTAgent，高於 naive pipeline。如果人手 deck 不是最高分，就是 gate 定義有誤，必須在任何迴圈開跑之前修訂。收斂效度問：SRR 是否跟隨人類偏好。該相關性會預先註冊，無論結果如何都會報告。

技術棧跟隨 brief：PyMuPDF 負責解析與裁圖、python-pptx 輸出原生可編輯檔、Streamlit 作示範前端、開發期間用 CodeBuddy 作 agent harness。

有兩處刻意偏離 brief 建議的時間表。第一，brief 把「檢查」放在第 5 階段（第 12–14 週）；本項目提前到第 5 週，因為指標必須先驗證，依賴它的迴圈才建得穩。第二，brief 第 6 階段列明比較六個維度：accuracy、coverage、readability、design、latency、cost。其中 coverage——論文的重點有幾多留在 deck 裡——會獨立量度，每篇標註五至八個 claim，令六個維度全部有數。

表 4. 對照大學時間表的排程。週次由 2026 年 10 月 26 日起算；到最後提交實際是 23 週，不是 brief 建議的 20 週。

週	工作流	交付	里程碑
W1–2　10/26–11/8	範圍與文獻	38 篇已讀；缺口確定	Proposal：11 月 5 日
W3–4　11/9–11/22	環境與 spike	解析與渲染可用	Workshop 1：TBC（≈11 月 9 日）
W5–7　11/23–12/13	Rulebook 與 detector	六個 gate；40 張校準	區辨效度檢查
W8–11　12/14–1/17	版面與修復	修復動作；110 張測試集	Interim：2027 年 1 月 7 日
W12–14　1/18–2/7	校準與迴圈	掃描凍結；迴圈收斂	首次 SRR 比較
W15–18　2/8–3/7	實驗與人評	消融；20 人研究	偏好相關性
W19–21　3/8–3/28	報告與示範	報告、demo、slides 初稿	指導老師審閱
W22–23　3/29–4/8	最後定稿	最終報告、demo、slides	Final：4 月 8 日；簡報 4 月 9–21 日

8. 聲明

本文件在撰寫與程式碼生成上使用了生成式 AI 工具。所有設計決定、指標定義、評測協議、標註與分析，均為作者本人所做。所用工具及其使用程度記錄於日誌，連同報告一併提交，符合大學的生成式 AI 使用指引。本文件亦作為最終提交的 AI 報告的基礎。

References

Chen, H., Zhou, X., Zhou, W., et al. (2026). X+Slides: Benchmarking audience-conditioned slide generation. arXiv:2606.19256.

Chen, X.-S., Zhu, J., Li, P.-L., Wang, H., & Guo, M.-H. (2026). PresentBench: A fine-grained rubric-based benchmark for slide generation. arXiv:2603.07244.

Hu, H., Dang, C., Liu, Y., et al. (2026). PosterMELD: Multi-agent paper-to-poster generation with editable print-ready outputs. arXiv:2608.02218.

Huang, Z., Liu, X., Hu, T., Zhang, K., & Liu, Y. (2025). PPTBench: Holistic evaluation of LLMs for PowerPoint layout and design understanding. arXiv:2512.02624.

IEEE Nanotechnology Materials and Devices Conference. (2021). Presentation preparation guidelines and requirements. https://ieeenmdc.org/past-conferences/nmdc-2021/call-for-papers/presentation-preparation-guidelines-and-requirements/

Liang, X., Zhang, Z., Zhang, X., Su, H., Xu, Y., Sun, S., & You, C. (2025). SlideGen: Collaborative multimodal agents for scientific slide generation. arXiv:2512.04529.

Jang, D., Heisler, M. L., Xing, L., et al. (2026). DECKBench: Benchmarking multi-agent frameworks for academic slide generation and editing. arXiv:2602.13318.

Ofengenden, M., Man, Y., Pang, Z., Gui, L.-Y., & Wang, Y.-X. (2025). PPTArena: A benchmark for PowerPoint editing. arXiv:2512.03042.

Ozden, T. C., VS, S., Horoz, F., et al. (2026). Narrative-driven paper-to-slide generation via ArcDeck. arXiv:2604.11969.

Pang, W., Lin, K. Q., Jian, X., He, X., & Torr, P. (2025). Paper2Poster: Towards multimodal poster automation from scientific papers. arXiv:2505.21497.

Tian, M., Zeng, Z., Yang, Y., et al. (2026). ReDeck: Step-level render-grounded refinement for document-to-slide generation. arXiv:2609.00194.

Vats, V., Sharma, K., & Wang, Y. (2026). SlideLab: Audience-centered scientific slide generation and evaluation. arXiv:2609.30294.

Zhang, Z. J., Chen, R., Zhong, M., & Wobbrock, J. O. (2025). SlideAudit: A dataset and taxonomy for automated evaluation of presentation slides. arXiv:2508.03630.

Zheng, H., Guan, X., Kong, H., et al. (2025). PPTAgent: Generating and evaluating presentations beyond text-to-slides. arXiv:2501.03936.

Zheng, H., Mo, G., Yan, X., et al. (2026a). DeepPresenter: Environment-grounded reflection for agentic presentation generation. arXiv:2602.22839.

Zheng, H., Wang, F., Xiong, T., et al. (2026b). SLIDEFORGE: An LLM agent for controllable editing of slides as structured artifacts. arXiv:2609.03109.